大模型越狱研究的演进主线

从优化提示，到搜索候选，再到学习与复用策略

2023—2026

从已有总结中精选 13 项工作

01 优化提示

2023.07

白盒 · 梯度优化

GCG

梯度与贪心搜索
逐词元优化对抗后缀

首次公开：2023 [20]

2023.10

白盒评分 · 遗传搜索

AutoDAN-Liu

分层遗传算法
演化保留语义的提示

ICLR 2024 [7]

02 搜索候选

2023.10

黑盒 · 反馈改写

PAIR

借助辅助攻击模型
按目标反馈迭代改写

首次公开：2023 N05

2023.12

黑盒 · 提示树搜索

TAP

扩展候选提示分支
剪去低效候选

NeurIPS 2024 N07

03 学习与复用策略

2024.06

黑盒 · 强化学习

RL-JACK

学习提示生成动作
以稠密奖励引导搜索

首次公开：2024 N16

2024.10

黑盒 · 策略自探索

AutoDAN-Turbo

自动发现并积累策略
跨任务复用经验

ICLR 2025 N18

近期阅读延伸

2026.10

黑盒 · 层次策略学习

TRAP

组织共享语义策略树
沿路径更新选择偏好

2026 年近期工作 N27

并行线索

表达方式、上下文长度、查询预算与外部审核，也在改变研究问题。

表达与预算

同一时期的不同扩展

2024 [10]
PAP
把有害指令嵌入说服上下文

2024 N32
Many-shot Jailbreaking
在长上下文中提供大量有害问答示范

实际组合

2024 / NeurIPS 2025 N26
Best-of-N
随机增强与重复采样；覆盖文本、视觉、音频

外部护栏攻防

从主模型到系统边界

2023 N08
Llama Guard
对输入和输出进行安全分类

2024 [9]
PRP
将通用对抗前缀传播到主模型响应

NDSS 2026 · 近期延伸 N25
DUALBREACH
联合优化绕过护栏与诱导主模型回答

读图：主线及灰色箭头表示按时间串联的研究议题，非直接继承；绿色箭头表示原文实际组合。

时间：按首次公开时间排序，节点间距不代表时间跨度；会议年另注。DUALBREACH 按 NDSS 2026 标示。

出处：DUALBREACH 第3–4页；TRAP 第2–4页；Best-of-N 第1、3、9页；相关原论文首页。完整出处见背景文献表。